3.2.1 Aplicación de Naive Bayes

December 26, 2020

1 Aplicación de Naive Bayes

1.1 Conceptos previos

Es uno de los algoritmos más simples y poderosos para la clasificación basado en el Teorema de Bayes con una suposición de **independencia entre los predictores**. Naive Bayes es fácil de construir y particularmente útil para conjuntos de datos muy grandes.

Naive Bayes asume que el efecto de una característica particular en una clase es independiente de otras características. Por ejemplo, un solicitante de préstamo es deseable o no dependiendo de sus ingresos, historial de préstamos y transacciones anteriores, edad y ubicación. Incluso si estas características son interdependientes, estas características se consideran de forma independiente.

Esta suposición simplifica la computación, es por esa razón el nombre del algoritmo **Bayes ingenuo**. Formalmente, esta suposición se denomina **independencia condicional de clase**.

$P(clase|Datos) = \frac{P(Datos|clase)*P(clase)}{P(Datos)}$

Donde: + clase es una salida en particular, en este caso será benigna

- datos son las características
- P(clase) se conoce como la **probabilidad anterior**. Es la probabilidad que ya se tiene
- P(Datos) se conoce como **probabilidad marginal**.
- P(clase|Datos) se conoce como **probabilidad posterior**. Es el resultado que se quiere encontrar
- P(Datos|clase) se conoce como **verosimilitud**

1.1.1 Cómo funciona

En caso de que se tenga una sola característica, el clasificador Naive Bayes calcula la probabilidad de un evento en los siguientes pasos:

- 1: calcular la probabilidad previa para las etiquetas de clase dadas.
- 2: determinar la probabilidad de probabilidad con cada atributo para cada clase.
- 3: poner estos valores en el teorema de Bayes y calcular la probabilidad posterior.
- 4: ver qué clase tiene una probabilidad más alta, dado que la variable de entrada pertenece a la clase de probabilidad más alta.

1.2 Set de datos

Se usará un set de datos precargado en scikit-learn que tiene relación con datos de muestras de biopsias que pueden ser benignas o malignas.

[6]:
```
#Carga de datos
import pandas as pd
import numpy as np
from sklearn import datasets
dataset = datasets.load_breast_cancer()
data_frame = pd.DataFrame(np.c_[dataset['data'], dataset['target']],
                          columns= np.append(dataset['feature_names'], ['target']))
data_frame
```

[6]:
```
     mean radius  mean texture  mean perimeter  mean area  mean smoothness  \
0          17.99         10.38          122.80     1001.0          0.11840
1          20.57         17.77          132.90     1326.0          0.08474
2          19.69         21.25          130.00     1203.0          0.10960
3          11.42         20.38           77.58      386.1          0.14250
4          20.29         14.34          135.10     1297.0          0.10030
..           ...           ...             ...        ...              ...
564        21.56         22.39          142.00     1479.0          0.11100
565        20.13         28.25          131.20     1261.0          0.09780
566        16.60         28.08          108.30      858.1          0.08455
567        20.60         29.33          140.10     1265.0          0.11780
568         7.76         24.54           47.92      181.0          0.05263

     mean compactness  mean concavity  mean concave points  mean symmetry  \
0             0.27760         0.30010              0.14710         0.2419
1             0.07864         0.08690              0.07017         0.1812
2             0.15990         0.19740              0.12790         0.2069
3             0.28390         0.24140              0.10520         0.2597
4             0.13280         0.19800              0.10430         0.1809
..                ...             ...                  ...            ...
564           0.11590         0.24390              0.13890         0.1726
565           0.10340         0.14400              0.09791         0.1752
566           0.10230         0.09251              0.05302         0.1590
567           0.27700         0.35140              0.15200         0.2397
568           0.04362         0.00000              0.00000         0.1587

     mean fractal dimension  ...  worst texture  worst perimeter  worst area  \
0                   0.07871  ...          17.33           184.60      2019.0
1                   0.05667  ...          23.41           158.80      1956.0
2                   0.05999  ...          25.53           152.50      1709.0
3                   0.09744  ...          26.50            98.87       567.7
4                   0.05883  ...          16.67           152.20      1575.0
..                      ...  ...            ...              ...         ...
```

```
564                 0.05623  ...          26.40           166.10      2027.0
565                 0.05533  ...          38.25           155.00      1731.0
566                 0.05648  ...          34.12           126.70      1124.0
567                 0.07016  ...          39.42           184.60      1821.0
568                 0.05884  ...          30.37            59.16       268.6

     worst smoothness  worst compactness  worst concavity  \
0              0.16220            0.66560           0.7119
1              0.12380            0.18660           0.2416
2              0.14440            0.42450           0.4504
3              0.20980            0.86630           0.6869
4              0.13740            0.20500            0.4000
..                 ...                ...              ...
564            0.14100            0.21130            0.4107
565            0.11660            0.19220           0.3215
566            0.11390            0.30940           0.3403
567            0.16500            0.86810           0.9387
568            0.08996            0.06444           0.0000

     worst concave points  worst symmetry  worst fractal dimension  target
0                  0.2654          0.4601                  0.11890     0.0
1                  0.1860          0.2750                  0.08902     0.0
2                  0.2430          0.3613                  0.08758     0.0
3                  0.2575          0.6638                  0.17300     0.0
4                  0.1625          0.2364                   0.07678    0.0
..                    ...             ...                      ...      ...
564                0.2216          0.2060                  0.07115     0.0
565                0.1628          0.2572                  0.06637     0.0
566                0.1418          0.2218                  0.07820     0.0
567                0.2650          0.4087                  0.12400     0.0
568                0.0000          0.2871                  0.07039     1.0

[569 rows x 31 columns]
```

[7]:
```
#Tipos de datos de las columnas
data_frame.dtypes
```

[7]:
```
mean radius                float64
mean texture               float64
mean perimeter             float64
mean area                  float64
mean smoothness            float64
mean compactness           float64
mean concavity             float64
mean concave points        float64
mean symmetry              float64
mean fractal dimension     float64
```

```
radius error                    float64
texture error                   float64
perimeter error                 float64
area error                      float64
smoothness error                float64
compactness error               float64
concavity error                 float64
concave points error            float64
symmetry error                  float64
fractal dimension error         float64
worst radius                    float64
worst texture                   float64
worst perimeter                 float64
worst area                      float64
worst smoothness                float64
worst compactness               float64
worst concavity                 float64
worst concave points            float64
worst symmetry                  float64
worst fractal dimension         float64
target                          float64
dtype: object
```

[9]:
```
data_frame.describe()
```

[9]:
```
       mean radius  mean texture  mean perimeter     mean area  \
count   569.000000    569.000000      569.000000  569.000000
mean     14.127292     19.289649       91.969033  654.889104
std       3.524049      4.301036       24.298981  351.914129
min       6.981000      9.710000       43.790000  143.500000
25%      11.700000     16.170000       75.170000  420.300000
50%      13.370000     18.840000       86.240000  551.100000
75%      15.780000     21.800000      104.100000  782.700000
max      28.110000     39.280000      188.500000 2501.000000

       mean smoothness  mean compactness  mean concavity  mean concave points  \
count       569.000000        569.000000      569.000000           569.000000
mean          0.096360          0.104341        0.088799             0.048919
std           0.014064          0.052813        0.079720             0.038803
min           0.052630          0.019380        0.000000             0.000000
25%           0.086370          0.064920        0.029560             0.020310
50%           0.095870          0.092630        0.061540             0.033500
75%           0.105300          0.130400        0.130700             0.074000
max           0.163400          0.345400        0.426800             0.201200

       mean symmetrymean fractal dimension  ...  worst texture  \
count      569.000000               569.000 ...     569.000000
```

```
mean          0.181162                  0.062798   ...      25.677223
std           0.027414                  0.007060   ...       6.146258
min           0.106000                  0.049960   ...      12.020000
25%           0.161900                  0.057700   ...      21.080000
50%           0.179200                  0.061540   ...      25.410000
75%           0.195700                  0.066120   ...      29.720000
max           0.304000                  0.097440   ...      49.540000

        worst perimeter   worst area  worst smoothness  worst compactness  \
count       569.000000   569.000000        569.000000         569.000000
mean        107.261213   880.583128          0.132369           0.254265
std          33.602542   569.356993          0.022832           0.157336
min          50.410000   185.200000          0.071170           0.027290
25%          84.110000   515.300000          0.116600           0.147200
50%          97.660000   686.500000          0.131300           0.211900
75%         125.400000  1084.000000          0.146000           0.339100
max         251.200000  4254.000000          0.222600           1.058000

        worst concavity  worst concave points  worst symmetry  \
count       569.000000            569.000000      569.000000
mean          0.272188              0.114606        0.290076
std           0.208624              0.065732        0.061867
min           0.000000              0.000000        0.156500
25%           0.114500              0.064930        0.250400
50%           0.226700              0.099930        0.282200
75%           0.382900              0.161400        0.317900
max           1.252000              0.291000        0.663800

        worst fractal dimension      target
count                569.000000  569.000000
mean                   0.083946    0.627417
std                    0.018061    0.483918
min                    0.055040    0.000000
25%                    0.071460    0.000000
50%                    0.080040    1.000000
75%                    0.092080    1.000000
max                    0.207500    1.000000

[8 rows x 31 columns]
```

1.2.1 Revisa la distribución de las observaciones respecto de la variable que se usará para la clasificación

[42]:
```
print(data_frame.groupby('target').size())
```

```
target
0.0    212
1.0    357
dtype: int64
```

[40]:
```
import matplotlib.pyplot as plt
#Gráfico de tortas del porcentaje de muestras benignas y malignas
#Contando las benignas
clases = np.array([data_frame[data_frame.target == 0.0].shape[0],␣
↪data_frame[data_frame.target == 1.0].shape[0]])

#Creando las leyendas del gráfico.
labels = [ str(round(x * 1.0 / clases.sum() * 100.0, 2)) + '%'    for x in clases␣
↪]
labels[0] = 'Benignas\n ' + labels[0]
labels[1] = 'Malignas\n ' + labels[1]

plt.pie(clases, labels=labels)
plt.title('Porcentaje de muestras beningnas y malignas')
plt.show()
```

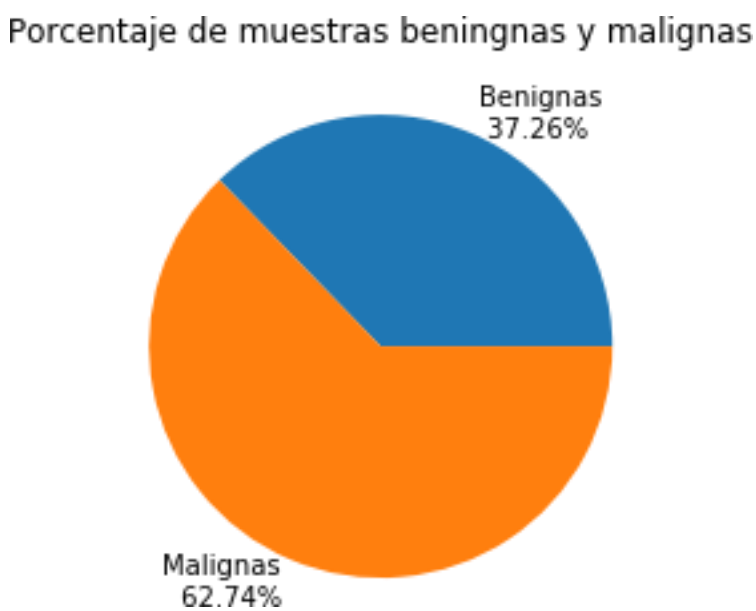

1.2.2 Comentarios hasta este punto

- Hay 569 observaciones con 31 columnas, siendo una de ellas la columna 'target' que es la que indica si es o no es cáncer.

- Se observa que hay una distribución aceptable de muestras malignas y benignas.

1.2.3 Análisis de distribución

[56]:
```
import seaborn as sns
columnas = np.array(data_frame.columns)

for col in columnas[:-1]:
    fig, ax =plt.subplots(1, 2, figsize=(20, 6))
    fig.suptitle(col, fontsize=18)
    sns.distplot(data_frame[col], ax=ax[0], kde=False)
    data_frame[[col]+['target']].plot.scatter(x=col, y='target', ax=ax[1])
    plt.show()
```

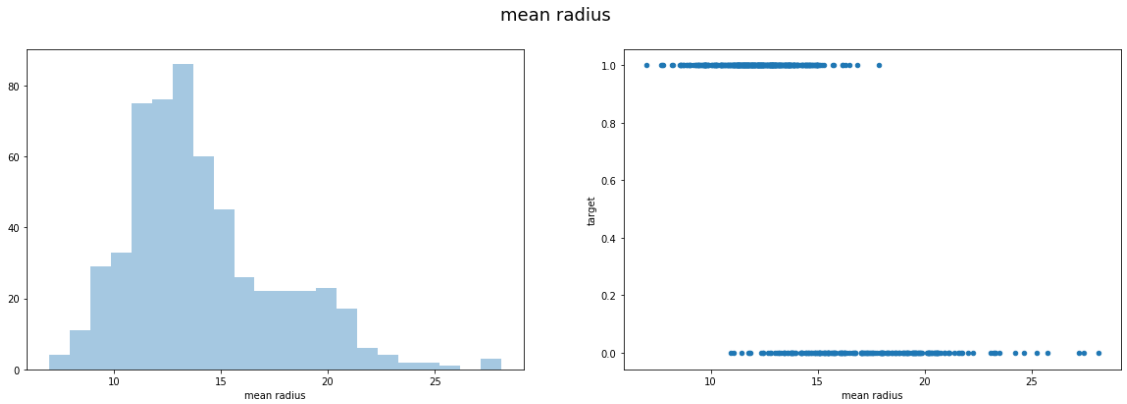

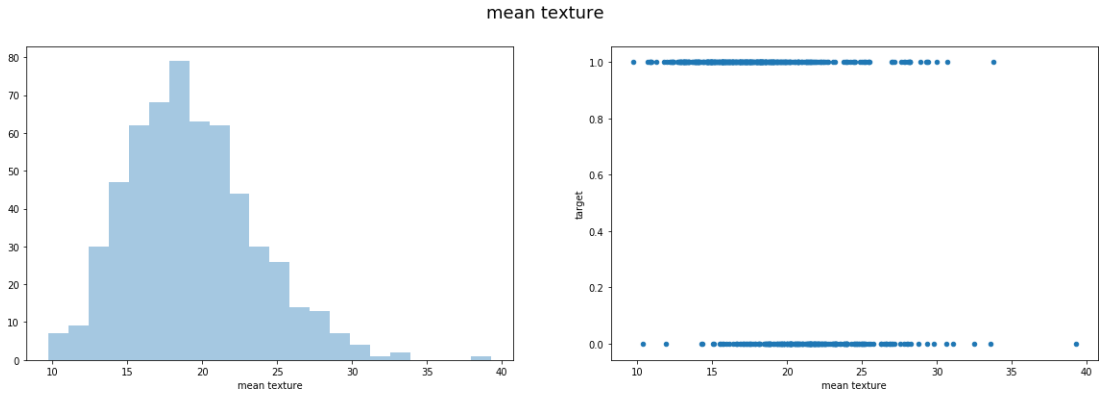

mean perimeter

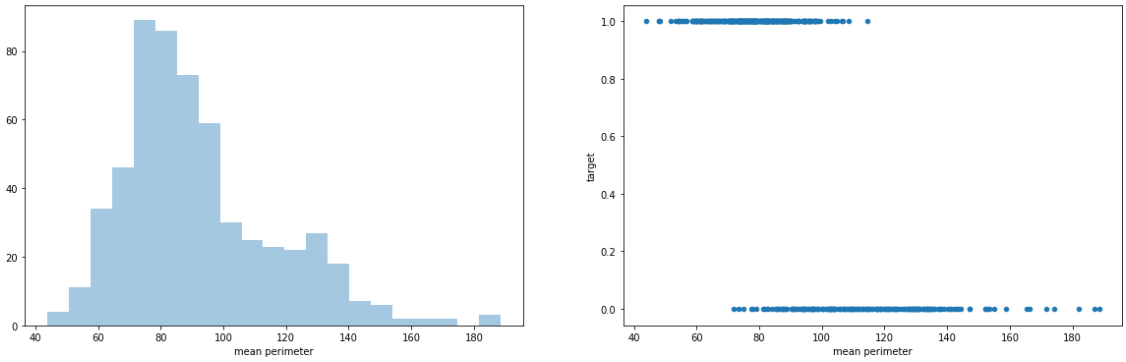

mean area

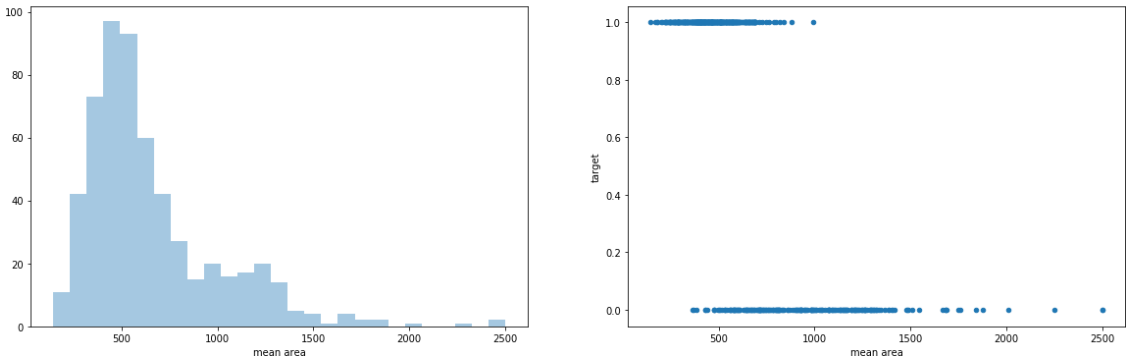

mean smoothness

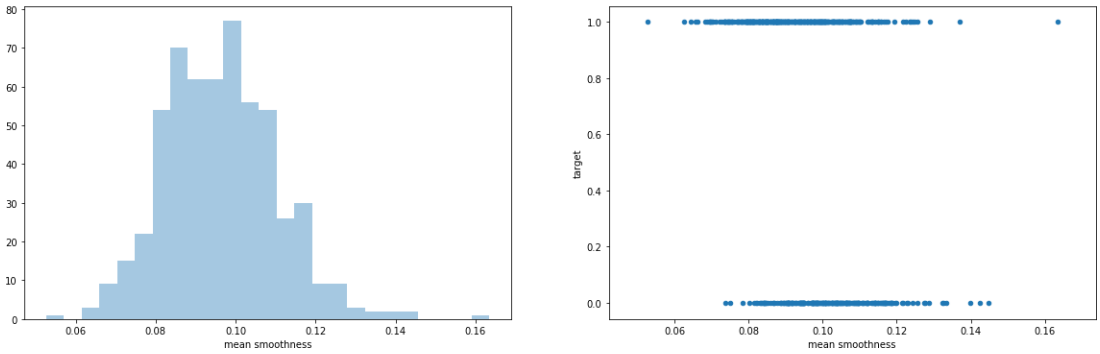

mean compactness

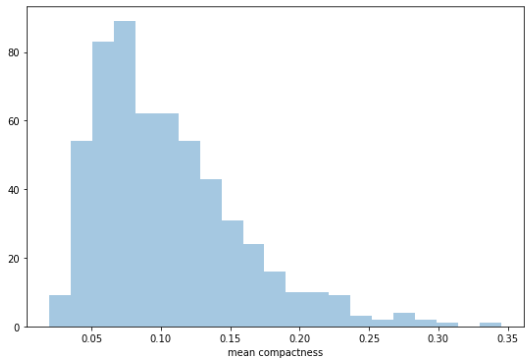

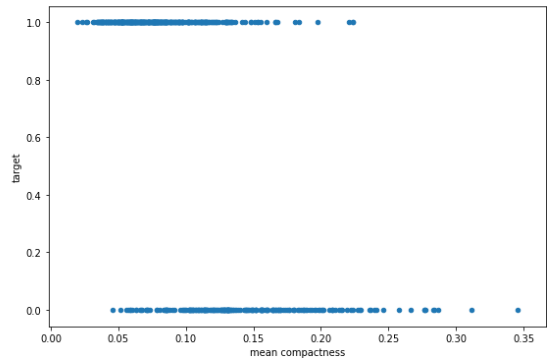

mean concavity

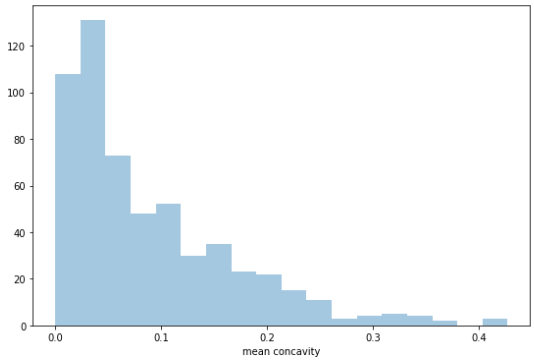

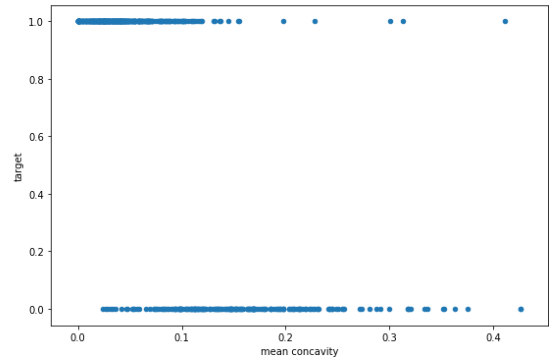

mean concave points

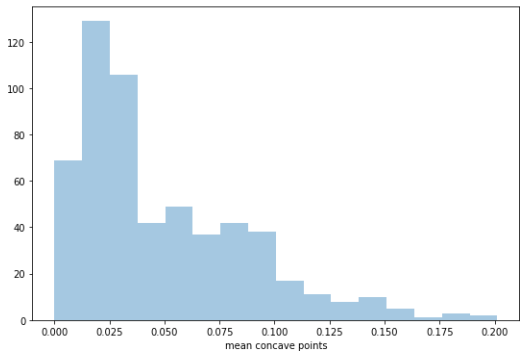

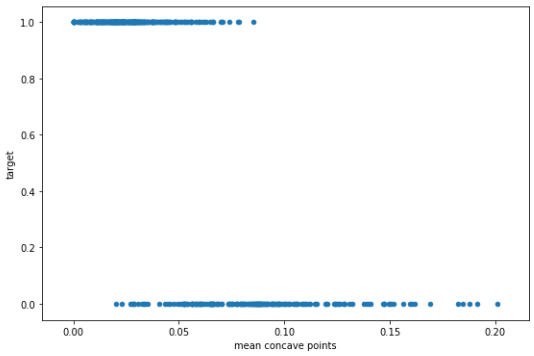

mean symmetry

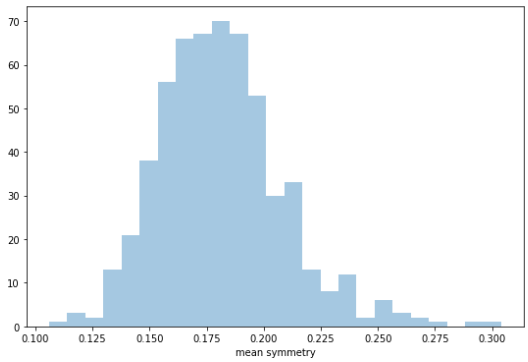

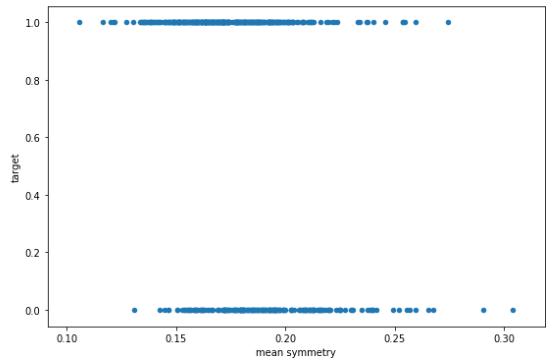

mean fractal dimension

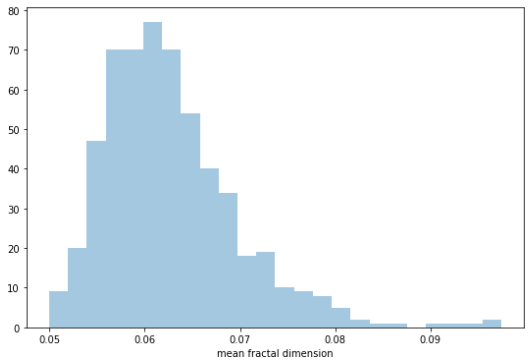

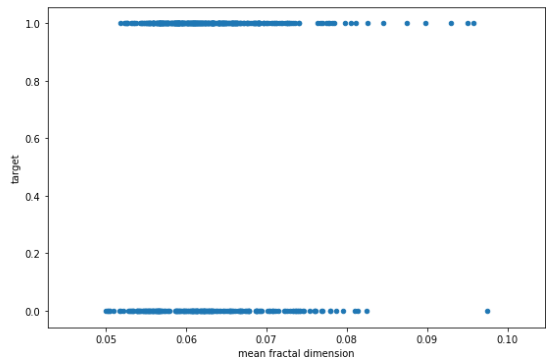

radius error

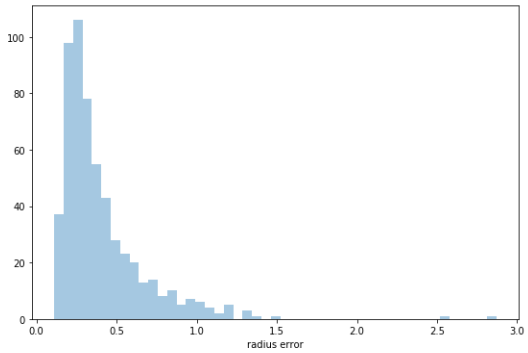

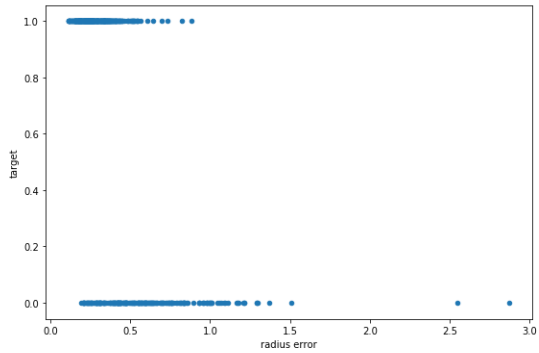

texture error

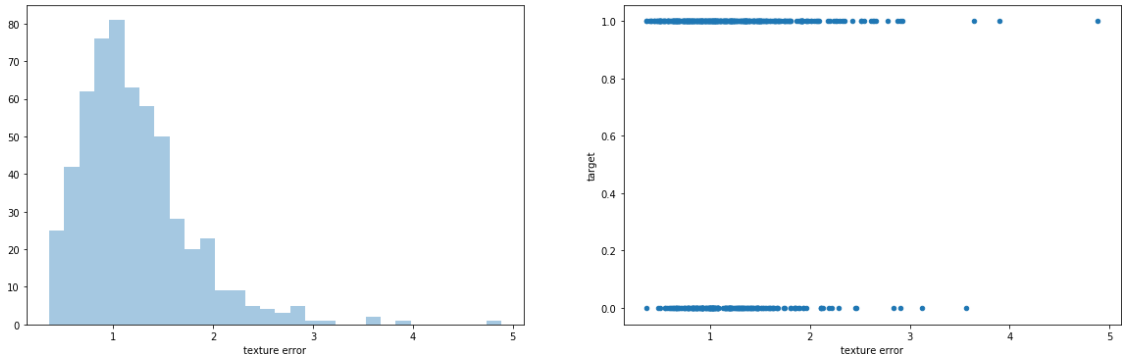

perimeter error

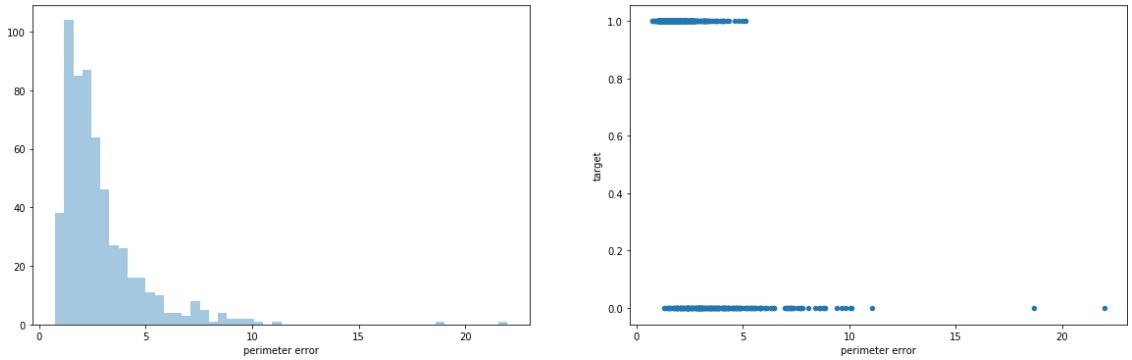

area error

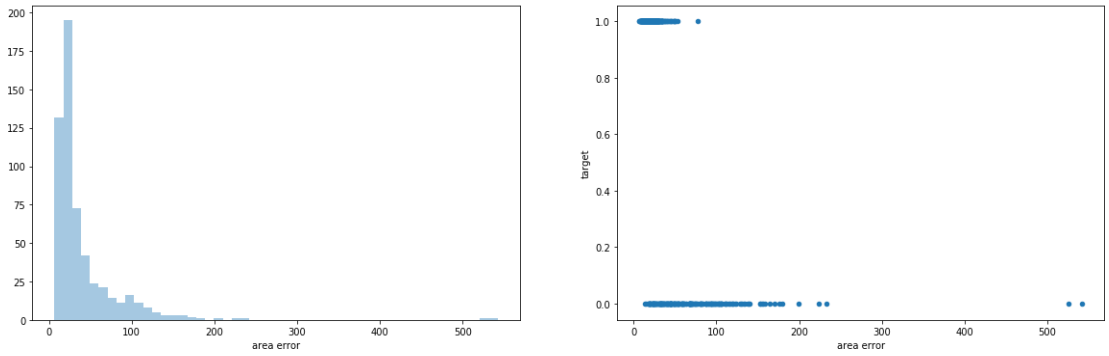

smoothness error

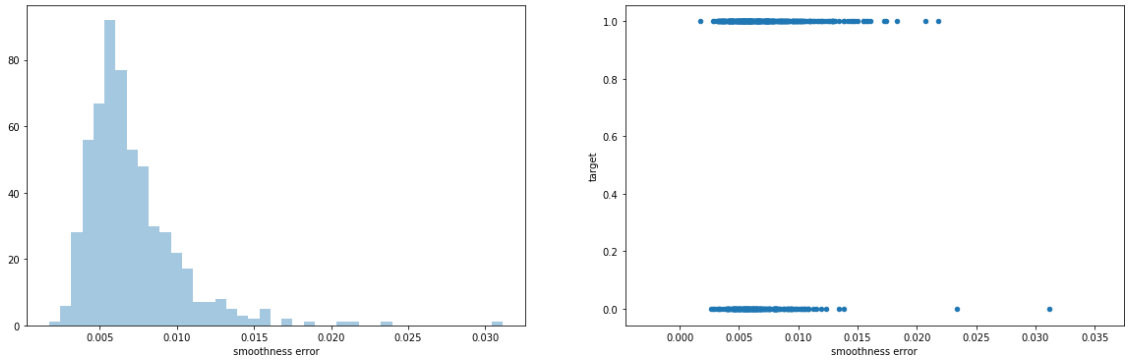

compactness error

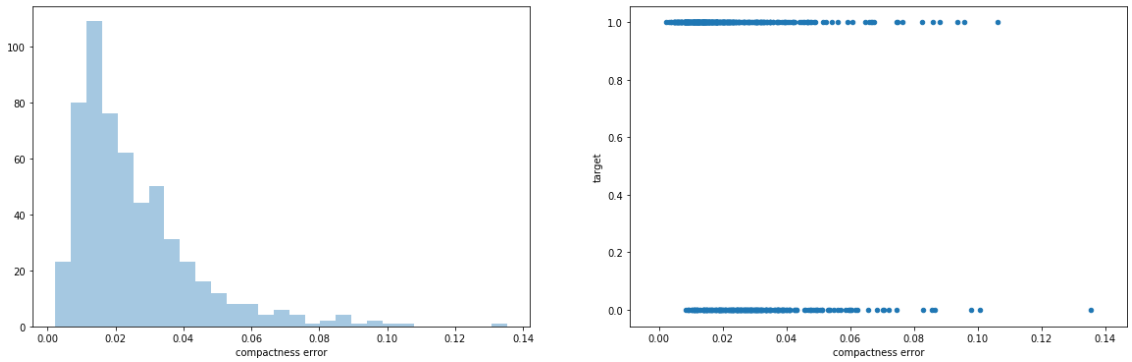

concavity error

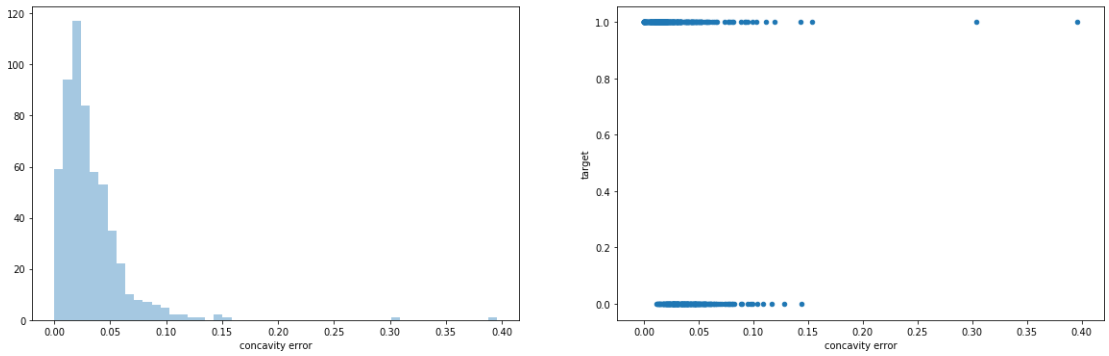

concave points error

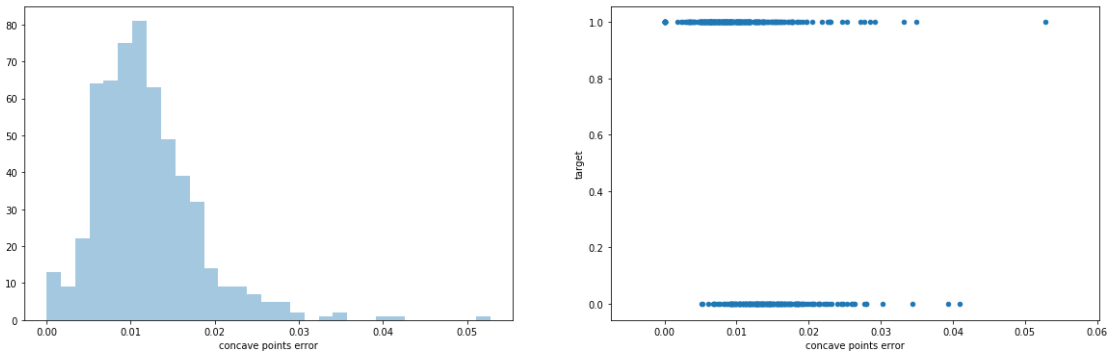

symmetry error

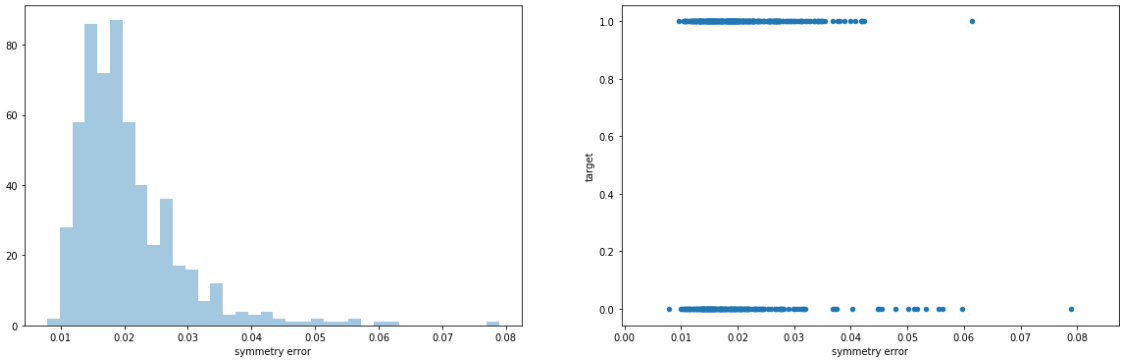

fractal dimension error

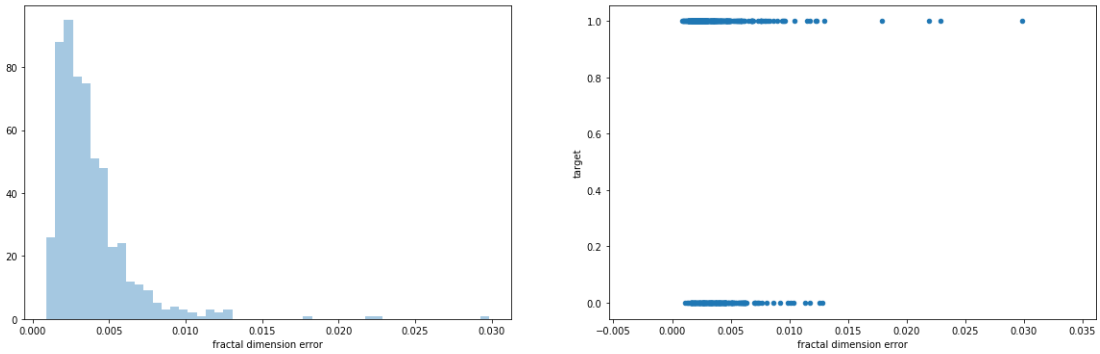

worst radius

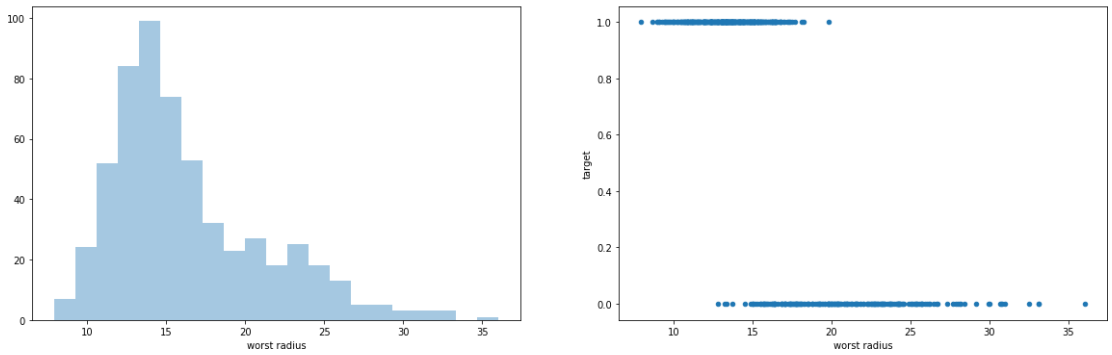

worst texture

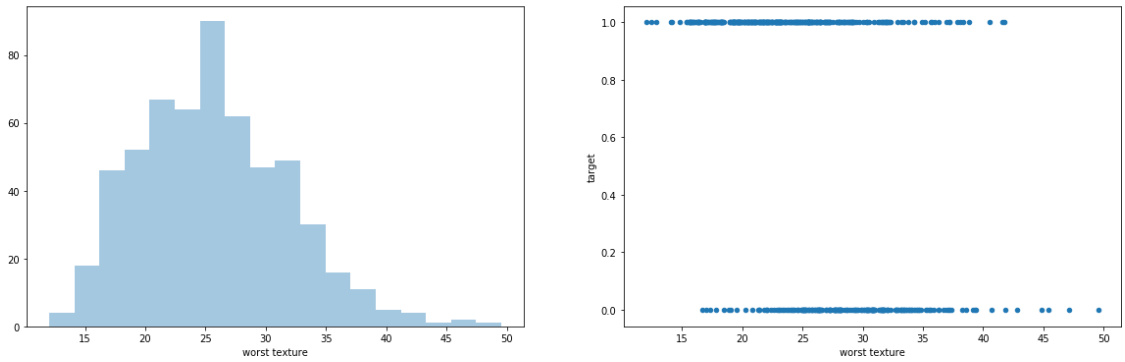

worst perimeter

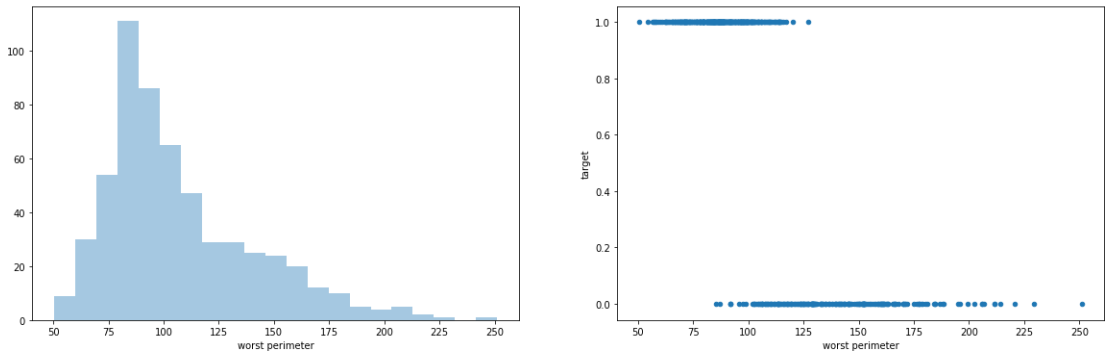

worst area

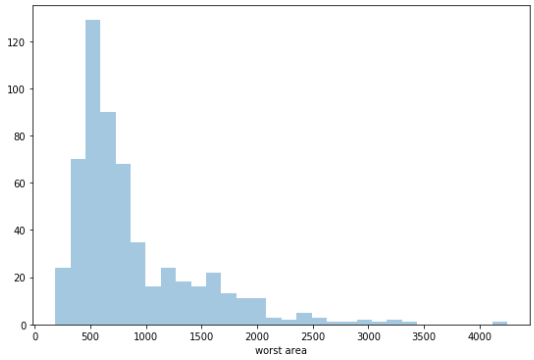

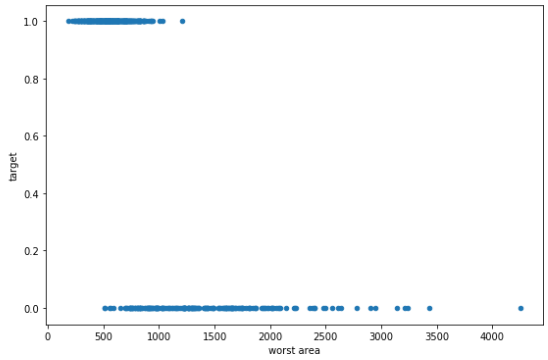

worst smoothness

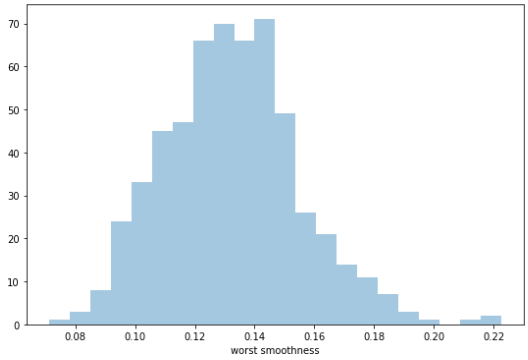

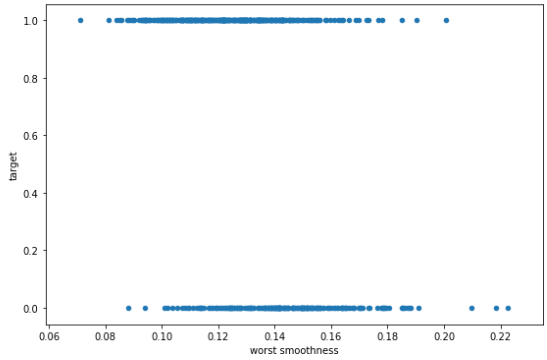

worst compactness

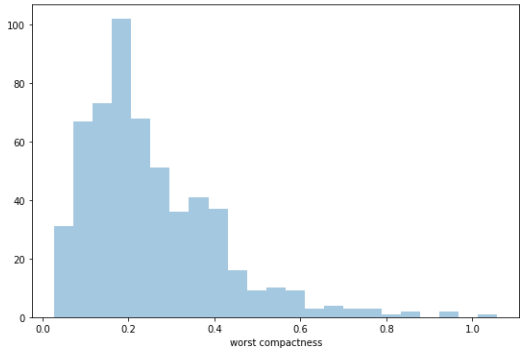

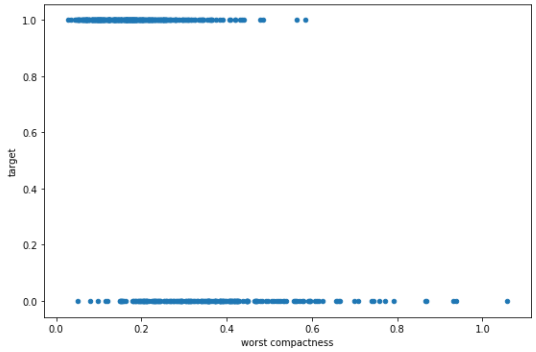

worst concavity

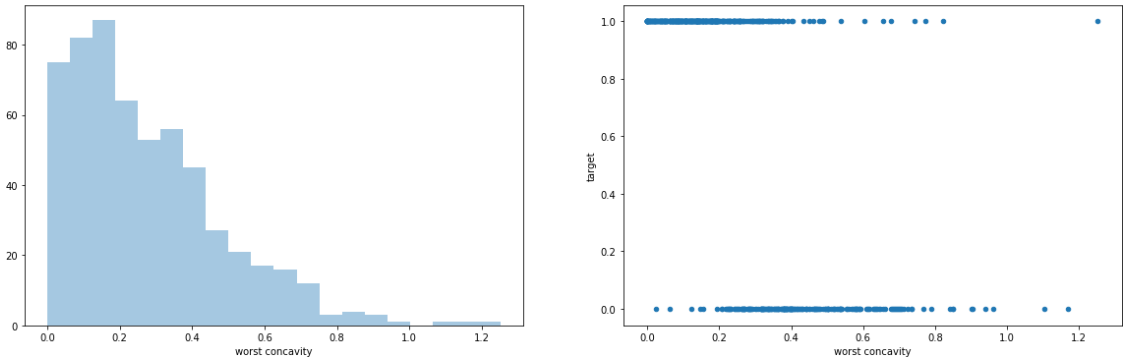

worst concave points

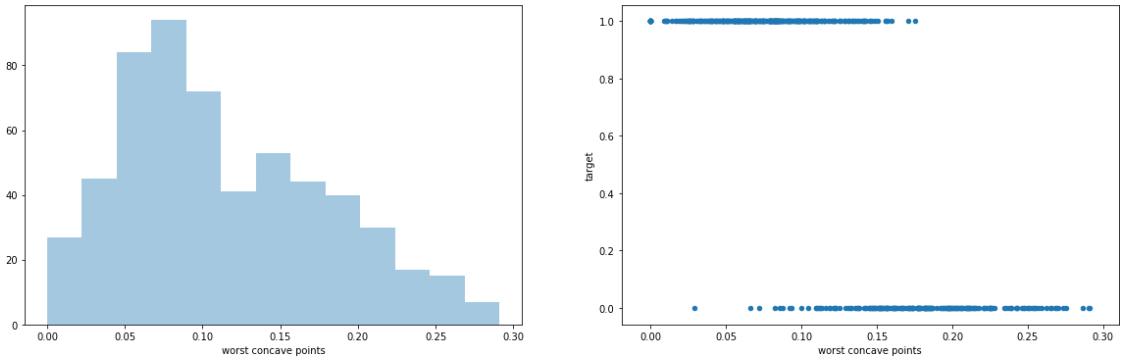

worst symmetry

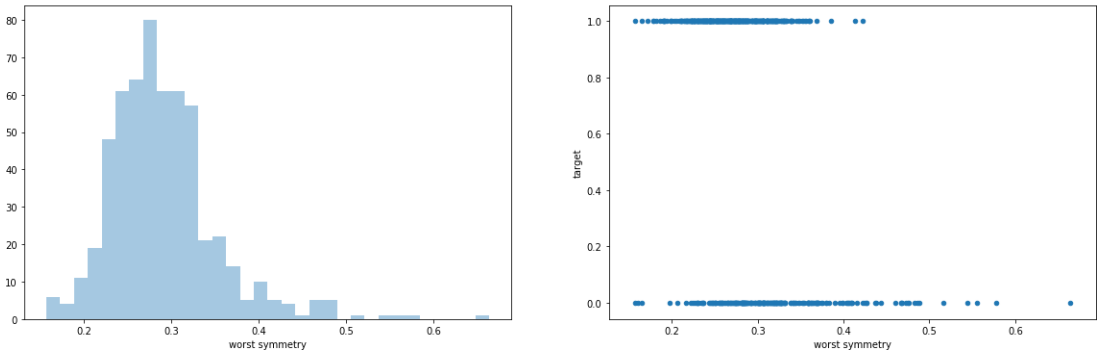

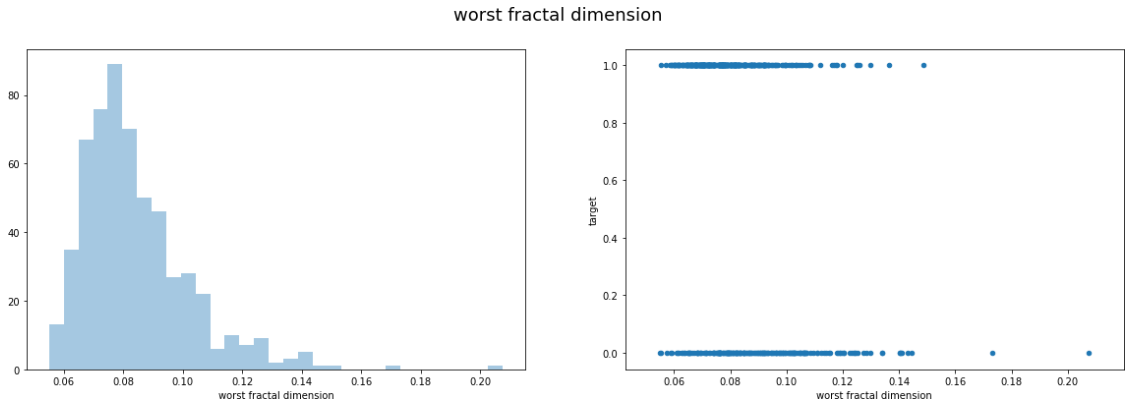

1.3 Preparación de los datos

[15]:
```
# Selecciona las variables
X = data_frame.drop(["target"],axis=1)

# Rescata la etiqueta
y = data_frame.target
```

1.4 Creando el modelo

1.4.1 Ideas previas

Se está tratando de elegir entre 2 clases: benigna o maligna; entonces una forma de tratar la decisión es calcular la tasa de probabilidades a posterior.

Cuando se trabaja con Naive Bayes se debe escoger un **clasificador**. Uno de los tipos de clasificadores más populares es el **Gaussian Naive Bayes Classifier**.

Hay otros clasificadores Bayesianos (https://scikit-learn.org/stable/modules/naive_bayes.html#).

La fórmula del clasificador, usando 2 clases (benigna, maligna) y 2 características (solo para explicar la fórmula): mean_radius, mean_texture.

$$P(benigna|datos) = \frac{P(benigna)*P(mean_radius|benigna)*P(mean_texture|benigna)}{P(datos)}$$

$$P(maligna|datos) = \frac{P(maligna)*P(mean_radius|maligna)*P(mean_texture|maligna)}{P(datos)}$$

donde:

- P(benigna) es la probabilidad que ya se tiene. Corresponde al número de veces que el valor de target = 0.0 en el conjunto de datos, dividido el total de observaciones. En este caso (como ya se revisó) es 212/569
- $P(mean_radius|benigna), P(mean_texture|benigna) $ es la verosimilitud.

Los nombres Gaussian y Naive (ingenuo) de algoritmo vienen de dos suposiciones:

- Se asume que las características de la verosimilitud no están correlacionadas entre ellas. Esto sería que el promedio de radio y la textura promedio son independientes entre ellos. Dado que eso no siempre puede ser cierto y es una suposición ingenua es que aparece en el nombre **naive bayes**
- Se asume que el valor de las características (mean_radius, mean_texture y todas las que se quieran agregar) tendrán una distribución normal (gaussiana). Esto permite calcular cada parte p(mean_radius|benigna) usando la función de probabilidad de densidad normal.

1.5 Obtención de datos de entrenamiento y validación

[21]:
```
from sklearn.model_selection import train_test_split

#Se separan los datos de "train" en entrenamiento y prueba para probar los␣
↪algoritmos
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,␣
↪random_state = 29)

# Define el algoritmo a utilizar Naive Bayes
from sklearn.naive_bayes import GaussianNB

modelo = GaussianNB()

# Entrenamiento del modelo
modelo.fit(X_train, y_train)

# Validación del modelo
y_pred = modelo.predict(X_test)
```

[22]:
```
#Evaluación del modelo
from sklearn.metrics import confusion_matrix

matriz = confusion_matrix(y_test, y_pred)
print('Matriz de Confusión:')
print(matriz)

# Se calcula la precisión del modelo
from sklearn.metrics import precision_score

precision = precision_score(y_test, y_pred)
print('Precisión del modelo:', precision)
```

```
Matriz de Confusión:
[[35  4]
 [ 3 72]]
```

Precisión del modelo:
0.9473684210526315

1.6 Interpretación de resultados

Desde la matriz de confusión:

- Se obtienen 106 datos predichos correctamente
- Se obtienen 8 datos erróneos

1.6.1 Acerca de la matriz de confusión

La imagen muestra la estructura de la matriz de confusión:

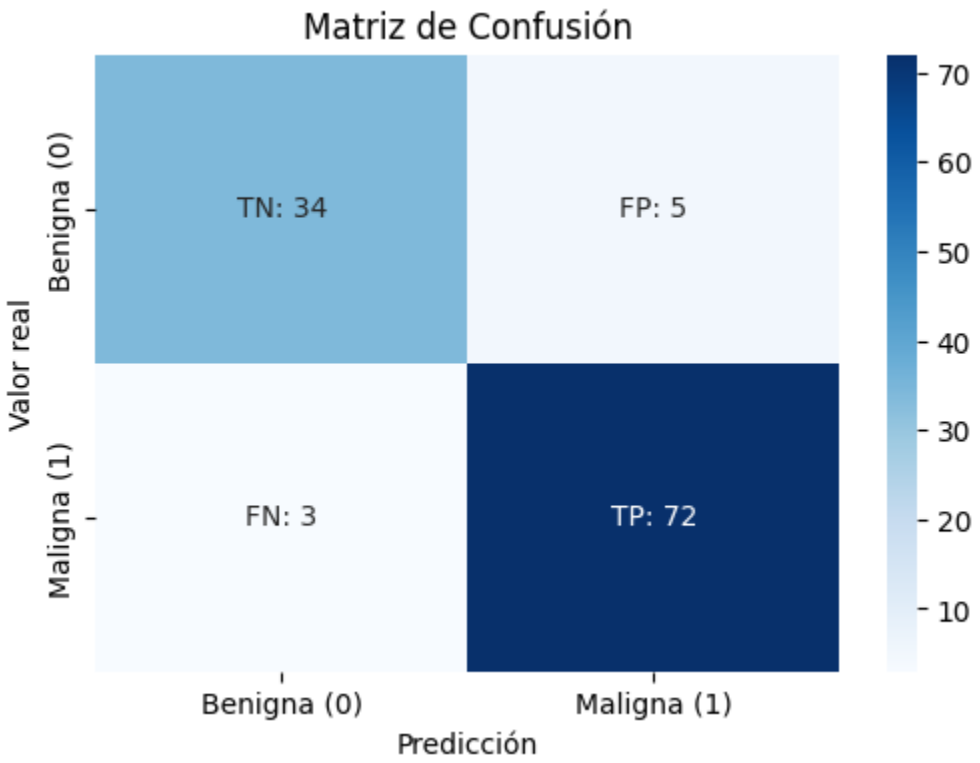

Si se considera que una muestra se dice benigna si está etiquetada como no cancerígena y maligna en caso contrario.

Considerando lo anterior esto se interpreta la matriz de la siguiente forma:

- 1. Muestra maligna y el modelo la clasificó como maligna (+). Esto sería un verdadero positivo o VP.
- 2. Muestra maligna y el modelo lo clasificó como benigna (-). Este sería un verdadero negativo o sea un VN.
- 3. Muestra benigna y el modelo lo clasificó como benigna (-). Este sería un error tipo II o falso negativo o FN.

- 4. Muestra benigna y el modelo lo clasificó como maligna (+) . Este es un error tipo I, o falso positivo o FP.

1.7 Otras medidas

https://scikit-learn.org/stable/modules/classes.html#sklearn-metrics-metrics

[67]:
```
from sklearn.metrics import accuracy_score, f1_score, recall_score

accuracy = accuracy_score(y_test, y_pred)
print('Accurancy del modelo:',accuracy)

print('F1 score del modelo:',f1_score(y_test, y_pred))
print('Recall del modelo:',recall_score(y_test, y_pred))
```

```
Accurancy del modelo: 0.9298245614035088
F1 score del modelo: 0.9473684210526316
Recall del modelo: 0.96
```

1.8 Usando un selector de columnas

Para mejorar los resultados con este algoritmo. En vez de utilizar las 30 columnas de datos de entrada que se tienen, se va a utilizar una Clase de SkLearn llamada **SelectKBest** con la que seleccionaremos las 5 mejores características y usarán sólo esas.

[58]:
```
from sklearn.feature_selection import SelectKBest
X=data_frame.drop(['target'], axis=1)
y=data_frame['target']

best=SelectKBest(k=5)
X_new = best.fit_transform(X, y)
X_new.shape
selected = best.get_support(indices=True)
print(X.columns[selected])
```

```
Index(['mean perimeter', 'mean concave points', 'worst radius',
       'worst perimeter', 'worst concave points'],
       dtype='object')
```

[60]:
```
import seaborn as sb
used_features =X.columns[selected]

colormap = plt.cm.viridis
plt.figure(figsize=(12,12))
plt.title('Pearson Correlation of Features', y=1.05, size=15)
sb.heatmap(data_frame[used_features].astype(float).corr(),linewidths=0.1,vmax=1.
↪0, square=True, cmap=colormap, linecolor='white', annot=True)
```

[60]: <matplotlib.axes._subplots.AxesSubplot at 0x7f825fa4f048>

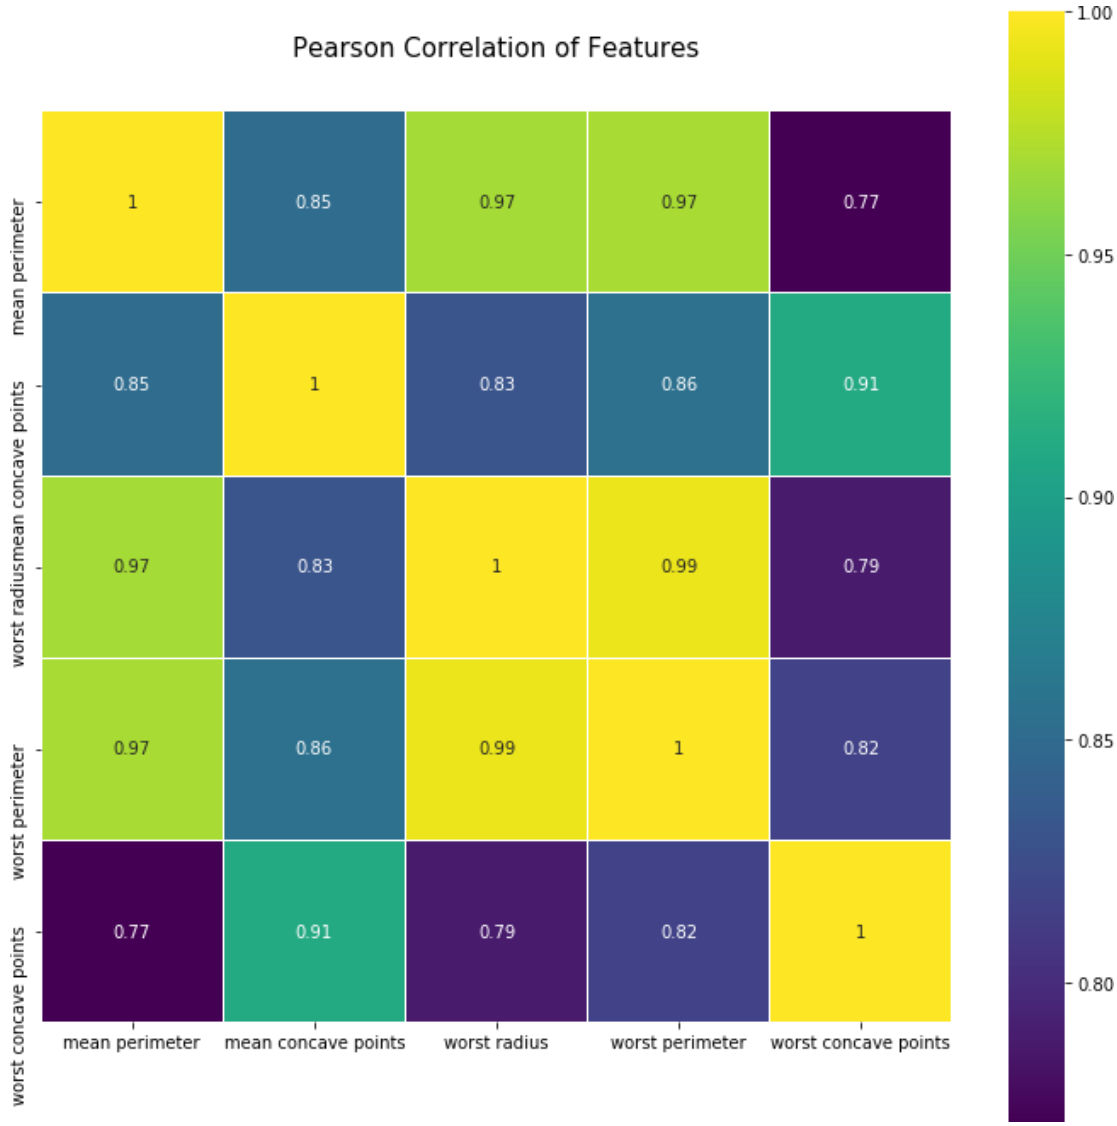

[62]:
```
X = data_frame[used_features]
#Se separan los datos de "train" en entrenamiento y prueba para probar los␣
↪algoritmos
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,␣
↪random_state = 29)

modelo_x = GaussianNB()

#Entrenamiento del modelo
modelo_x.fit(X_train, y_train)
```

```
#Validación del modelo
y_pred = modelo_x.predict(X_test)
```

[63]:
```
#Evaluación del modelo
matriz_x = confusion_matrix(y_test, y_pred)
print('Matriz de Confusión:')
print(matriz_x)

precision = precision_score(y_test, y_pred)
print('Precisión del modelo:')
print(precision)
```

```
Matriz de Confusión:
[[34  5]
 [ 3 72]]
Precisión del modelo:
0.935064935064935
```